

# Redes soma-produto e sua relação com redes bayesianas

Tiago Madeira  
<madeira@ime.usp.br>

PCS5708 – Técnicas de Raciocínio Probabilístico em Inteligência Artificial

Prof. Paulo Sergio Cugnasca  
Escola Politécnica – Universidade de São Paulo

Maio de 2018

# Roteiro

- 1 Introdução
  - Motivação
  - Projeto
- 2 Noções intuitivas dos fundamentos
  - Redes soma-produto
  - Diagramas de decisão algébrica
- 3 De redes soma-produto para redes bayesianas
  - Representação gráfica
  - Algoritmo de Zhao et al.
- 4 Conclusão
  - Distribuições, tratabilidade e compactibilidade
  - Considerações finais

# Motivação (1/2)

**Redes soma-produto** (*Sum-Product Network* = *SPN*)<sup>1</sup> são modelos profundos tratáveis para inferência probabilística.

Resultados muito bons para diversas aplicações como modelagem de linguagem<sup>2</sup>, classificação e reconstrução de imagens<sup>1</sup>.

---

<sup>1</sup>POON, H. DOMINGOS, P. Sum-Product Networks: A New Deep Architecture (2011). *Uncertainty in Artificial Intelligence (UAI 2011)*

<sup>2</sup>CHENG, W. KOK, S. PHAM, H. CHIEU, H. MING, K. CHAI, A. Language Modeling with Sum-Product Networks (2014). Disponível em <http://spn.cs.washington.edu/papers/is14.pdf>

## Motivação (2/2)

Em 2015, artigo<sup>3</sup> apresentou conexão teórica entre redes soma-produto e redes bayesianas (*Bayesian Network* = *BN*), junto com algoritmo polinomial para realizar conversão.

**O que essa conexão pode nos dizer sobre o conhecimento probabilístico codificado nas redes soma-produto?**

---

<sup>3</sup>ZHAO, H. MELIBARI, M. POUPART, P. On the Relationship between Sum-Product Networks and Bayesian Networks (2015). Disponível em <http://arxiv.org/abs/1501.01239>


# No que consiste o projeto?

- Estudo sobre redes soma-produto e sua relação com redes bayesianas
- Implementação de algoritmo para construir uma rede bayesiana a partir de uma rede soma-produto

# Redes soma-produto (Poon & Domingos, 2011)


Uma rede soma-produto é um **grafo acíclico dirigido enraizado** de somas e produtos, no qual folhas são indicadores de variáveis ou distribuições univariadas.

Arestas que saem de nós do tipo soma são ponderadas com um peso não-negativo.




# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$



# Redes soma-produto (Poon & Domingos, 2011)


•  $P(X_1, \bar{X}_2) = ?$






# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$




## Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

•  $P(X_1, \bar{X}_2) = ?$



# Redes soma-produto (Poon & Domingos, 2011)


- $P(X_1, \bar{X}_2) = ?$






# Redes soma-produto (Poon & Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{?}$




## Redes soma-produto (Poon &amp; Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$




# Redes soma-produto (Poon & Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$
- $P(X_1) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$
- $P(X_1) = \frac{2370}{3500}$




# Redes soma-produto (Poon & Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$
- $P(X_1) = \frac{2370}{3500}$
- $P(\bar{X}_2 | X_1) = ?$




# Redes soma-produto (Poon & Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$
- $P(X_1) = \frac{2370}{3500}$
- $P(\bar{X}_2|X_1) = \frac{P(X_1, \bar{X}_2)}{P(X_1)}$



## Redes soma-produto (Poon &amp; Domingos, 2011)


- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$
- $P(X_1) = \frac{2370}{3500}$
- $P(\bar{X}_2|X_1) = \frac{P(X_1, \bar{X}_2)}{P(X_1)} = \frac{1776}{2370}$



## Redes soma-produto (Poon &amp; Domingos, 2011)

- $P(X_1, \bar{X}_2) = \frac{1776}{3500}$
- $P(X_1) = \frac{2370}{3500}$
- $P(\bar{X}_2|X_1) = \frac{P(X_1, \bar{X}_2)}{P(X_1)} = \frac{1776}{2370}$


⇒ inferência em tempo linear






# Propriedades de redes soma-produto


- **Escopo** de um nó: conjunto de variáveis na sub-rede enraizada em tal nó [*scope*]
- **SPN decomponível**: todo nó produto tem filhos com escopos disjuntos [*decomposable*]
- **SPN completa**: todo nó soma tem filhos com o mesmo escopo [*complete/smooth*]



# Forma normal



(a) SPN completa e decomponível.




(b) Mesma SPN na forma normal.

## Forma normal

Exemplo:

$$P(X_1, \bar{X}_2) = \frac{1776}{3500} \quad \checkmark$$



(b) Mesma SPN na forma normal.

## Diagramas de decisão algébrica (Bahar *et al*, 1993)


Um diagrama de decisão algébrica<sup>4</sup> (*Algebraic Decision Diagram = ADD*) é um **grafo acíclico dirigido enraizado** que representa uma função de variáveis com domínio finito.

Intuitivamente é como uma árvore de decisão, mas mais compacto porque explora subgrafos isomórficos.


---

<sup>4</sup>BAHAR, R. FROHM, E. GAONA, C. HACHTEL, G. MACII, E. PARDO, A. SOMENZI, F. Algebraic decision diagrams and their applications (1993). Disponível em <https://doi.org/10.1109/ICCAD.1993.580054>

## Exemplo de ADD binária e relação com árvore de decisão




(a) Representação de uma função de variáveis binárias com árvore de decisão.




(b) Representação da mesma função com diagrama de decisão algébrica.

# Representação gráfica



**Redes bayesianas:**  
Representação gráfica de  
dependências diretas




**Redes soma-produto:**  
Representação gráfica da  
computação

## Algoritmo de Zhao *et al.* (2015)


Dada uma SPN normal  $\mathcal{S}$  sobre variáveis booleanas  $X_{1:N}$ , retorna uma rede bayesiana  $\mathcal{B}$  que representa a mesma distribuição com  $|\mathcal{B}| = O(N|\mathcal{S}|)$ .

- 1 Construção da **estrutura**
- 2 Computação das **distribuições de probabilidade condicional**  
(*conditional probability distribution = CPD*)

# Algoritmo de Zhao et al. (2015) - Estrutura (1/2)



(a) SPN na forma normal.



(b) Estrutura da BN correspondente.



## Algoritmo de Zhao *et al.* (2015) - Estrutura (2/2)

Quando fazemos inferência, implicitamente estamos marginalizando as variáveis ocultas.

A rede bayesiana resultante tem uma **estrutura bipartida** com uma camada de variáveis ocultas apontando para uma camada de variáveis observáveis.



## Algoritmo de Zhao *et al.* (2015) - CPDs (1/3)

**Variáveis ocultas:** Seja  $H_v$  a variável oculta correspondente ao nó soma  $v$  de  $\mathcal{S}$ . Seja  $l$  o grau de saída de  $v$ . Como a SPN é normal temos  $\sum_{i=1}^l w_i = 1$  e  $w_i \geq 0 \quad \forall i$ .

Isso sugere tomar  $P(H_v = i) = w_i$ .

*E as variáveis observáveis?*

# Algoritmo de Zhao et al. (2015) - CPDs (2/3)



(a) Sub-SPNs usadas para calcular CPDs.

(b) BN correspondente com ADDs.






## Algoritmo de Zhao *et al.* (2015) - CPDs (3/3)


Como a SPN é decomponível, cada nó produto tem filhos com escopos disjuntos. Para cada variável observável  $X$ , construímos uma ADD extraíndo de  $\mathcal{S}$  a sub-SPN induzida por  $X$  e contraindo todos seus nós produto.

Percorremos a ADD para encontrar  $P(X|H_1 = h_1^*, \dots, H_m = h_m^*)$ .



## Exemplos (1/2)



## Exemples (2/2)



## Exemplos (2/2)






## Conclusões de Zhao et al. (2015)

- 1 A BN resultante da conversão tem estrutura simples (bipartida), mas é possível relacionar a profundidade de uma SPN com a *treewidth* da BN — **mais camadas** → **maior *treewidth*, distribuições mais complexas.**
- 2 Pode haver **outras técnicas** para converter uma SPN numa BN com uma representação mais compacta e um *treewidth* menor.
- 3 Algoritmos para aprender estrutura e parâmetros de SPNs **podem ser usados** para aprender BNs com ADDs.

## Distribuições, tratabilidade e compactibilidade<sup>5</sup>



A: SPNs tratáveis = SPNs compactas = BNs tratáveis

B: BNs compactas

C: SPNs gerais = BNs gerais

---

<sup>5</sup>POUPART, P. Guest Lecture in STAT946: Deep Learning, University of Waterloo. Disponível em <https://www.youtube.com/watch?v=Nm0jNq0nQ2o>

## Considerações finais

- Redes soma-produto são um **modelo relativamente novo e promissor**. Estudar sua teoria é interessante porque há muitas questões em aberto e alguns equívocos na literatura, como mostra Peharz (2015)<sup>6</sup>.
- Pretende-se disponibilizar o **código implementado** (em Go) publicamente na Internet.

---

<sup>6</sup>PEHARZ, R. Foundations of Sum-Product Networks for Probabilistic Modeling (2015). PhD Thesis.

# Fim

Se alguém tiver interesse na apresentação ou na monografia:

`<madeira@ime.usp.br>`

**Perguntas e comentários?**